

# 目录

|                               |   |
|-------------------------------|---|
| 工业轴承设备剩余寿命预测系统的实现：数据语义与样本构造说明 | 2 |
| 文档信息                          | 2 |
| 修订记录                          | 2 |
| 1. 数据语义为什么重要                  | 2 |
| 2. 两个数据集的共同点和差异               | 2 |
| 3. BearingEntity 的统一含义        | 3 |
| 4. 快照、窗口和特征序列                 | 4 |
| 5. RUL 标签时间单位                 | 4 |
| 6. 多轴承特征观察                    | 5 |
| 7. 数据泄漏防范                     | 5 |
| 8. 源码和测试依据                    | 5 |

# 工业轴承设备剩余寿命预测系统的实现：数据语义与样本构造说明

## 文档信息

| 项目    | 内容                          |
|-------|-----------------------------|
| 文档名称  | 数据语义与样本构造说明                 |
| 文档编号  | SE-PHM-FINAL-23             |
| 文档阶段  | 结题                          |
| 项目名称  | 工业轴承设备剩余寿命预测系统的实现           |
| 课程    | 中国科学技术大学软件学院《软件工程》          |
| 指导老师  | zjf                         |
| 小组成员  | zyj、cyy、zdh、zy              |
| 文档负责人 | cyy                         |
| 参与编写  | zyj、zdh、zy                  |
| 版本    | V1.0                        |
| 修订日期  | 2026-06-14                  |
| 归档形式  | Markdown 源文件、PDF、DOCX       |
| 内容基线  | 数据来源、采样语义、RUL 标签、样本构造、防泄漏原则 |

## 修订记录

| 版本   | 日期         | 编写人 | 说明                    |
|------|------------|-----|-----------------------|
| V1.0 | 2026-06-14 | 项目组 | 新增两个真实数据集的数据语义和样本构造说明 |

## 1. 数据语义为什么重要

轴承 RUL 预测不能把原始文件只当作普通表格处理。每个文件代表一个按时间采集的振动快照，每个快照在全寿命序列中有明确顺序，每个窗口或特征序列都对应一个剩余寿命标签。如果忽略时间顺序，模型评估很容易产生数据泄漏，导致结果偏乐观。

## 2. 两个数据集的共同点和差异

XJTU-SY 与 PHM2012/FEMTO 都是 run-to-failure 轴承退化数据，适合做剩余寿命预测、健康指标构造和退化趋势分析。二者的差异主要体现在采样组织方式：

真实数据多轴承特征摘要：前 20% 与后 20% 对比




Figure 1: 多轴承特征摘要

| 项目       | XJTU-SY        | PHM2012/FEMTO                           |
|----------|----------------|-----------------------------------------|
| 采样频率     | 25.6 kHz       | 25.6 kHz                                |
| 单个快照点数   | 32768          | 2560                                    |
| 单个快照覆盖时长 | 1.28 s         | 0.1 s                                   |
| 快照间隔     | 约 1 min        | 约 10 s                                  |
| 通道       | 水平、垂直振动        | 水平、垂直振动，另有温度文件                          |
| 组织方式     | 三工况、多个轴承完整寿命序列 | Learning/Test/Validation/Full_Test 竞赛语义 |

这说明两个 loader 的目标不是简单拼接文件，而是把不同数据源整理成统一的 `BearingEntity`。这里需要特别区分两个时间概念：

| 概念      | XJTU-SY                     | PHM2012/FEMTO             | 对 RUL 的影响                                  |
|---------|-----------------------------|---------------------------|--------------------------------------------|
| 单快照覆盖时长 | 32768 点 / 25.6 kHz = 1.28 s | 2560 点 / 25.6 kHz = 0.1 s | 决定单个文件内部信号长度和 FFT 分辨率                      |
| 相邻快照间隔  | 约 60 s                      | 约 10 s                    | 决定 <code>elapsed_seconds</code> 与秒级 RUL 标签 |

因此，`1.csv` 或 `acc_00001.csv` 不是一段连续寿命的全部数据，而是运行过程中的短时间高频快照。RUL 标签主要依赖相邻快照间隔，而不是单个快照覆盖时长。

### 3. BearingEntity 的统一含义

`BearingEntity` 是数据层向后续模块提供的统一实体。它包含：

| 字段                        | 作用                                                  |
|---------------------------|-----------------------------------------------------|
| <code>entity_id</code>    | 轴承编号，如 <code>Bearing1_1</code>                      |
| <code>dataset_name</code> | 数据集名称，如 <code>XJTU-SY</code> 或 <code>PHM2012</code> |
| <code>samples</code>      | 按时间顺序排列的快照表                                         |
| <code>sample_rate</code>  | 振动采样率                                               |

| 字段       | 作用                   |
|----------|----------------------|
| metadata | 工况、时间间隔、RUL 单位、原始路径等 |

在 samples 中，最重要的列是 sample\_index、elapsed\_seconds、rul、水平/垂直振动信号和原始文件名。后续特征、标签和训练都建立在这些列之上。

## 4. 快照、窗口和特征序列

项目中有三个容易混淆的概念：

| 概念                    | 含义                  | 在系统中的用途         |
|-----------------------|---------------------|-----------------|
| 快照 snapshot           | 一次采样文件中的原始振动点       | loader 输出       |
| 窗口 window             | 对单个长信号切分得到的片段       | 原始 CNN/RNN 模型输入 |
| 特征序列 feature sequence | 多个连续快照的 19 维特征拼成的序列 | 论文复现和特征模型输入     |

直接输入原始信号能保留更多细节，但计算成本较高，也不利于答辩中解释数据规律。本项目在论文复现主线中优先使用 19 维特征序列：每个快照先转成特征向量，再按时间顺序组成长度 5 或 10 的序列。

## 5. RUL 标签时间单位

对于完整寿命序列，RUL 的基本公式是：

$$RUL_i = T_{end} - t_i$$

其中  $t_i$  是当前快照的运行时间， $T_{end}$  是该轴承最后一个有效快照对应的时间。XJTU-SY 可按约 1 分钟快照间隔换算；PHM2012 可按约 10 秒快照间隔换算。若只使用文件序号或抽样序号，输出中必须说明是快照级 RUL，不能误写成秒级寿命。

PHM2012 的 Test\_set 还涉及官方给出的终止 RUL 条目。系统需要保留该信息来源，不能只用本地文件数推断真实终止寿命。

PHM2012 的 split 语义在建模时单独处理：

| split                       | 数据含义                   | 本项目处理                                         |
|-----------------------------|------------------------|-----------------------------------------------|
| Learning_set / Training_set | 完整 run-to-failure 寿命序列 | 按最后快照倒推秒级 RUL，适合主线训练和演示                       |
| Test_set                    | 截断观测序列，比赛要求预测截断点之后寿命   | 若官方终止 RUL 条目可用，则写入 known_terminal_rul_seconds |
| Full_Test_Set               | 部分镜像中提供更完整测试记录         | 作为补充目录解析，不替代论文划分说明                            |

温度文件只存在于 PHM2012。PHM2012Loader 会把 temp\_\*.csv 与同编号 acc\_\*.csv 对齐并保存在 Temperature 通道；当前 RUL 主线模型优先使用水平或垂直振动特征，温度通道保留为后续多源融合扩展。

## 6. 多轴承特征观察

`scripts/generate_project_owner_assets.py` 从真实 `data/external` 中读取多个代表轴承，每个轴承均匀抽样 80 个快照。摘要统计采用同一口径：前 20% 抽样快照作为早期，后 20% 抽样快照作为后期，再比较 RMS、峰值、峭度、峰值因子、谱能量、谱熵和综合健康指标。生成的 `multi-bearing-feature-summary.csv` 是本图的数据来源。

| 数据集     | 代表轴承       | RMS 后期/早期 | 峰值后期/早期 | 谱能量后期/早期 | 谱熵后期/早期 | 观察            |
|---------|------------|-----------|---------|----------|---------|---------------|
| XJTU-SY | Bearing1_1 | 5.60      | 4.36    | 33.03    | 0.72    | 强度和频谱能量后期显著抬升 |
| XJTU-SY | Bearing1_3 | 4.75      | 7.27    | 27.26    | 0.81    | 同工况下峰值变化更突出   |
| XJTU-SY | Bearing2_1 | 3.46      | 4.54    | 31.73    | 0.92    | 工况变化影响寿命跨度和幅值 |
| XJTU-SY | Bearing3_1 | 2.72      | 2.86    | 25.05    | 0.88    | 长寿命样本退化更平缓    |
| PHM2012 | Bearing1_1 | 4.03      | 6.26    | 23.37    | 0.90    | 后期增强明显，波动更密集  |
| PHM2012 | Bearing1_2 | 1.70      | 1.58    | 4.70     | 1.01    | 同工况不同轴承差异明显   |
| PHM2012 | Bearing2_1 | 1.75      | 2.55    | 3.93     | 1.03    | 工况和样本长度共同影响特征 |
| PHM2012 | Bearing3_1 | 1.07      | 1.19    | 1.53     | 1.06    | 短序列中趋势不一定单调   |

这些结果说明，特征分析不能只展示单个轴承曲线。答辩中应说明代表图是局部证据，多轴承摘要用于补充统计视角。

均匀抽样和前后 20% 统计只用于可视化分析，不等同于训练/测试切分；论文复现仍按轴承编号、工况和时间顺序组织样本。

## 7. 数据泄漏防范

RUL 是时间相关目标，不能把相邻窗口随机打散到训练集和测试集。否则模型可能在训练集中看到与测试样本高度相邻的退化片段，导致评估偏乐观。

本项目采用以下划分原则：

| 实验目标  | 推荐划分               |
|-------|--------------------|
| 快速演示  | 单轴承按时间顺序切分         |
| 同工况泛化 | 同一工况多个轴承训练，留一个轴承测试 |
| 论文复现  | 按论文给出的轴承编号和工况划分    |
| 跨工况分析 | 一个或多个工况训练，另一个工况测试  |

该原则在 `xLSTM-Transformer` 复现中体现得最明显：XJTU-SY 与 PHM2012 均按论文工况和轴承编号组织训练/测试。

## 8. 源码和测试依据

| 内容           | 源码依据                            | 测试/输出依据                                        |
|--------------|---------------------------------|------------------------------------------------|
| XJTU-SY 目录解析 | <code>dataset/xjtu.py</code>    | <code>tests/test_data_io_and_loaders.py</code> |
| PHM2012 目录解析 | <code>dataset/phm2012.py</code> | loader 测试、复现 workflow                          |

| 内容       | 源码依据                   | 测试/输出依据                     |
|----------|------------------------|-----------------------------|
| 统一实体     | data/entities.py       | dataset split 测试            |
| 特征抽取     | feature/engineering.py | 19 维特征测试、特征摘要图              |
| RUL 序列标签 | labeling/labelers.py   | feature sequence labeler 测试 |