

目录

工业轴承设备剩余寿命预测系统的实现：数据语义与样本构造说明	2
文档信息	2
修订记录	2
1. 数据语义为什么重要	2
2. 两个数据集的共同点和差异	2
3. BearingEntity 的统一含义	3
4. 快照、窗口和特征序列	4
5. RUL 标签时间单位	4
6. 多轴承特征观察	5
7. 数据泄漏防范	5
8. 源码和测试依据	5

工业轴承设备剩余寿命预测系统的实现：数据语义与样本构造说明

文档信息

项目	内容
文档名称	数据语义与样本构造说明
文档编号	SE-PHM-FINAL-23
文档阶段	结题
项目名称	工业轴承设备剩余寿命预测系统的实现
课程	中国科学技术大学软件学院《软件工程》
指导老师	zjf
小组成员	zyj、cyy、zdh、zy
文档负责人	cyy
参与编写	zyj、zdh、zy
版本	V1.0
修订日期	2026-06-14
归档形式	Markdown 源文件、PDF、DOCX
内容基线	数据来源、采样语义、RUL 标签、样本构造、防泄漏原则

修订记录

版本	日期	编写人	说明
V1.0	2026-06-14	项目组	新增两个真实数据集的数据语义和样本构造说明

1. 数据语义为什么重要

轴承 RUL 预测不能把原始文件只当作普通表格处理。每个文件代表一个按时间采集的振动快照，每个快照在全寿命序列中有明确顺序，每个窗口或特征序列都对应一个剩余寿命标签。如果忽略时间顺序，模型评估很容易产生数据泄漏，导致结果偏乐观。

2. 两个数据集的共同点和差异

XJTU-SY 与 PHM2012/FEMTO 都是 run-to-failure 轴承退化数据，适合做剩余寿命预测、健康指标构造和退化趋势分析。二者的差异主要体现在采样组织方式：

真实数据多轴承特征摘要：前 20% 与后 20% 对比




Figure 1: 多轴承特征摘要

项目	XJTU-SY	PHM2012/FEMTO
采样频率	25.6 kHz	25.6 kHz
单个快照点数	32768	2560
单个快照覆盖时长	1.28 s	0.1 s
快照间隔	约 1 min	约 10 s
通道	水平、垂直振动	水平、垂直振动，另有温度文件
组织方式	三工况、多个轴承完整寿命序列	Learning/Test/Validation/Full_Test 竞赛语义

这说明两个 loader 的目标不是简单拼接文件，而是把不同数据源整理成统一的 `BearingEntity`。这里需要特别区分两个时间概念：

概念	XJTU-SY	PHM2012/FEMTO	对 RUL 的影响
单快照覆盖时长	32768 点 / 25.6 kHz = 1.28 s	2560 点 / 25.6 kHz = 0.1 s	决定单个文件内部信号长度和 FFT 分辨率
相邻快照间隔	约 60 s	约 10 s	决定 <code>elapsed_seconds</code> 与秒级 RUL 标签

因此，`1.csv` 或 `acc_00001.csv` 不是一段连续寿命的全部数据，而是运行过程中的短时间高频快照。RUL 标签主要依赖相邻快照间隔，而不是单个快照覆盖时长。

3. BearingEntity 的统一含义

`BearingEntity` 是数据层向后续模块提供的统一实体。它包含：

字段	作用
<code>entity_id</code>	轴承编号，如 <code>Bearing1_1</code>
<code>dataset_name</code>	数据集名称，如 <code>XJTU-SY</code> 或 <code>PHM2012</code>
<code>samples</code>	按时间顺序排列的快照表
<code>sample_rate</code>	振动采样率

字段	作用
metadata	工况、时间间隔、RUL 单位、原始路径等

在 samples 中，最重要的列是 sample_index、elapsed_seconds、rul、水平/垂直振动信号和原始文件名。后续特征、标签和训练都建立在这些列之上。

4. 快照、窗口和特征序列

项目中有三个容易混淆的概念：

概念	含义	在系统中的用途
快照 snapshot	一次采样文件中的原始振动点	loader 输出
窗口 window	对单个长信号切分得到的片段	原始 CNN/RNN 模型输入
特征序列 feature sequence	多个连续快照的 19 维特征拼成的序列	论文复现和特征模型输入

直接输入原始信号能保留更多细节，但计算成本较高，也不利于答辩中解释数据规律。本项目在论文复现主线中优先使用 19 维特征序列：每个快照先转成特征向量，再按时间顺序组成长度 5 或 10 的序列。

5. RUL 标签时间单位

对于完整寿命序列，RUL 的基本公式是：

$$RUL_i = T_{end} - t_i$$

其中 t_i 是当前快照的运行时间， T_{end} 是该轴承最后一个有效快照对应的时间。XJTU-SY 可按约 1 分钟快照间隔换算；PHM2012 可按约 10 秒快照间隔换算。若只使用文件序号或抽样序号，输出中必须说明是快照级 RUL，不能误写成秒级寿命。

PHM2012 的 Test_set 还涉及官方给出的终止 RUL 条目。系统需要保留该信息来源，不能只用本地文件数推断真实终止寿命。

PHM2012 的 split 语义在建模时单独处理：

split	数据含义	本项目处理
Learning_set / Training_set	完整 run-to-failure 寿命序列	按最后快照倒推秒级 RUL，适合主线训练和演示
Test_set	截断观测序列，比赛要求预测截断点之后寿命	若官方终止 RUL 条目可用，则写入 known_terminal_rul_seconds
Full_Test_Set	部分镜像中提供更完整测试记录	作为补充目录解析，不替代论文划分说明

温度文件只存在于 PHM2012。PHM2012Loader 会把 temp_*.csv 与同编号 acc_*.csv 对齐并保存在 Temperature 通道；当前 RUL 主线模型优先使用水平或垂直振动特征，温度通道保留为后续多源融合扩展。

6. 多轴承特征观察

`scripts/generate_project_owner_assets.py` 从真实 `data/external` 中读取多个代表轴承，每个轴承均匀抽样 80 个快照。摘要统计采用同一口径：前 20% 抽样快照作为早期，后 20% 抽样快照作为后期，再比较 RMS、峰值、峭度、峰值因子、谱能量、谱熵和综合健康指标。生成的 `multi-bearing-feature-summary.csv` 是本图的数据来源。

数据集	代表轴承	RMS 后期/早期	峰值后期/早期	谱能量后期/早期	谱熵后期/早期	观察
XJTU-SY	Bearing1_1	5.60	4.36	33.03	0.72	强度和频谱能量后期显著抬升
XJTU-SY	Bearing1_3	4.75	7.27	27.26	0.81	同工况下峰值变化更突出
XJTU-SY	Bearing2_1	3.46	4.54	31.73	0.92	工况变化影响寿命跨度和幅值
XJTU-SY	Bearing3_1	2.72	2.86	25.05	0.88	长寿命样本退化更平缓
PHM2012	Bearing1_1	4.03	6.26	23.37	0.90	后期增强明显，波动更密集
PHM2012	Bearing1_2	1.70	1.58	4.70	1.01	同工况不同轴承差异明显
PHM2012	Bearing2_1	1.75	2.55	3.93	1.03	工况和样本长度共同影响特征
PHM2012	Bearing3_1	1.07	1.19	1.53	1.06	短序列中趋势不一定单调

这些结果说明，特征分析不能只展示单个轴承曲线。答辩中应说明代表图是局部证据，多轴承摘要用于补充统计视角。

均匀抽样和前后 20% 统计只用于可视化分析，不等同于训练/测试切分；论文复现仍按轴承编号、工况和时间顺序组织样本。

7. 数据泄漏防范

RUL 是时间相关目标，不能把相邻窗口随机打散到训练集和测试集。否则模型可能在训练集中看到与测试样本高度相邻的退化片段，导致评估偏乐观。

本项目采用以下划分原则：

实验目标	推荐划分
快速演示	单轴承按时间顺序切分
同工况泛化	同一工况多个轴承训练，留一个轴承测试
论文复现	按论文给出的轴承编号和工况划分
跨工况分析	一个或多个工况训练，另一个工况测试

该原则在 `xLSTM-Transformer` 复现中体现得最明显：XJTU-SY 与 PHM2012 均按论文工况和轴承编号组织训练/测试。

8. 源码和测试依据

内容	源码依据	测试/输出依据
XJTU-SY 目录解析	<code>dataset/xjtu.py</code>	<code>tests/test_data_io_and_loaders.py</code>
PHM2012 目录解析	<code>dataset/phm2012.py</code>	loader 测试、复现 workflow

内容	源码依据	测试/输出依据
统一实体	data/entities.py	dataset split 测试
特征抽取	feature/engineering.py	19 维特征测试、特征摘要图
RUL 序列标签	labeling/labelers.py	feature sequence labeler 测试