

轴承寿命预测与故障诊断系统

术语、标签、特征与分析指标详解

PHM 项目文档

2026 年 6 月 19 日

摘要

本文档面向不熟悉轴承故障诊断和 PHM 的读者，解释本项目中出现的核心名词、数据形态、标签构造、FPT 与 3σ 原则、RUL、健康状态、早期故障检测、故障类型阶段、特征工程、特征分析指标和实验产物。阅读目标是：即使读者不是本领域人员，也能理解本项目为什么要从振动信号中提取特征，为什么要构造 RUL 和健康状态标签，以及为什么某些特征适合寿命预测、某些特征更适合早期故障检测。

目录

1	先用一句话理解本项目	4
2	PHM 是什么	4
3	轴承和振动信号的基本概念	5
3.1	轴承为什么能从振动里看出问题	5
3.2	一个 CSV 文件在项目里代表什么	5
4	数据集术语	6
4.1	XJTU-SY	6
4.2	PHM2012 / PRONOSTIA	6
5	标签、任务和目标变量	7
5.1	标签 label 是什么	7
5.2	RUL: Remaining Useful Life	7
5.2.1	线性 RUL	7
5.2.2	分段 RUL	8
5.3	退化 degradation	8

5.4	HI: Health Indicator	8
5.5	FPT: First Predictable Time	9
5.6	3σ 原则 / Three Sigma	9
5.7	健康状态 Health State	9
5.8	早期故障 Early Fault	10
5.9	故障类型阶段 Fault Type Stage	10
6	数据划分和泄漏	10
6.1	Train / Validation / Test	10
6.2	数据泄漏 Data Leakage	11
7	原始信号、通道和特征命名	11
7.1	通道命名	11
7.2	特征列命名规则	11
8	时间域特征	12
8.1	manual_basic 当前启用的时间域特征	12
8.2	代码支持但 manual_basic 未默认启用的时间域特征	12
9	频域特征	13
9.1	manual_basic 当前启用的频域特征	13
9.2	代码支持但 manual_basic 未默认启用的频域特征	13
10	manual_basic 的完整特征列	14
10.1	时间域 30 个特征列	14
10.2	频域 15 个特征列	14
11	tsfresh 特征	15
11.1	tsfresh minimal 的特征计算器	15
11.2	tsfresh efficient 的特征类型	16
11.3	tsfresh efficient 当前计算器名称总览	16
12	特征清洗和标准化	18
13	特征分析 Stage 6	18

14 RUL 特征分析指标	19
14.1 相关性	19
14.2 退化行为分数	19
15 健康状态特征分析指标	19
16 早期故障检测指标	20
17 故障类型特征分析	21
18 哪些特征通常适合哪些任务	21
19 如何阅读分析结果	22
20 常见误解澄清	22
21 本项目命令示例	23
22 缩写表	23
23 一句话总结	24

1 先用一句话理解本项目

本项目研究的是滚动轴承预测性维护。轴承在机器中负责支撑旋转部件。它从健康到失效通常不是瞬间发生，而是经历一个逐渐退化的过程：开始时振动很平稳，随后出现微小冲击或频率成分变化，最后振动幅值和冲击明显增大，设备接近失效。

本项目要做两类判断：

- 1. 还能用多久？ 这对应 RUL（Remaining Useful Life，剩余使用寿命）预测。
- 2. 现在处于什么状态？ 这对应健康状态评估、早期故障检测和故障类型阶段识别。

项目中数据流可以概括为：

原始振动 CSV → 样本索引 → 窗口/快照级特征 → RUL/健康状态/早期故障标签 → 任务数据集 → 模型训练与分

其中最容易混淆的一点是：原始数据本身通常只是振动信号，不直接告诉我们每一时刻是 healthy、slight、moderate 还是 severe。项目里的许多标签是根据轴承全寿命顺序、HI（健康指标）和 FPT（首次可预测时间）构造出来的伪标签或任务标签。

2 PHM 是什么

PHM 是 Prognostics and Health Management 的缩写，中文常译为故障预测与健康管理。它不是单纯的“分类器”或“回归器”，而是一整套面向设备运维的技术体系。

名词	通俗解释
Diagnosis 诊断	判断设备现在是否已经异常、异常属于哪一类。例如：轴承是否有外圈故障。
Prognosis 预测	判断设备未来还能安全运行多久。例如：还剩 30 分钟、50 个采样周期或 20% 寿命。
Health Management 健康管理	把诊断和预测结果用于维修计划、备件安排、停机风险控制。
Predictive Maintenance 预测性维护	不等坏了再修，也不固定周期盲目换件，而是根据状态和寿命预测安排维修。

本项目中的 PHM 主要落在两个任务上：

- RUL 回归：输出一个连续数值，表示剩余寿命。
- 状态/故障分类：输出离散类别，例如 healthy / slight / moderate / severe，或者 early fault 的 0/1。

3 轴承和振动信号的基本概念

3.1 轴承为什么能从振动里看出问题

轴承由内圈、外圈、滚动体和保持架组成。理想情况下，旋转很平稳；当某个部件出现点蚀、裂纹、剥落或磨损时，滚动体经过缺陷位置会产生冲击，冲击会传到传感器上，表现为加速度信号的变化。

术语	含义
内圈 Inner Race	与转轴一起旋转的轴承圈。内圈故障常随旋转调制，特征频率复杂。
外圈 Outer Race	通常固定在轴承座上。外圈缺陷经过滚动体时会产生周期性冲击。
滚动体 Ball/Roller	在内圈和外圈之间滚动的球或滚子。滚动体故障可能导致宽频冲击。
保持架 Cage	分隔滚动体的结构。保持架故障可能引起低频调制或不稳定冲击。
振动加速度	本项目主要使用的信号类型，单位可理解为“振动强弱随时间变化的记录”。
水平/垂直通道	两个传感器方向。XJTU-SY 和 PHM2012 都有水平、垂直两个振动方向。

3.2 一个 CSV 文件在项目里代表什么

本项目把一个原始振动 CSV 文件视为一个**振动快照**或**样本**。这个样本不是一个单点，而是一小段连续振动信号。

- XJTU-SY：每个 CSV 通常是一次采集快照，包含水平和垂直两列振动信号。
- PHM2012：每个 acc_*.csv 通常包含时间列和水平/垂直加速度列；当前框架只保留最后两列加速度。

项目中的样本级索引字段包括：

字段	解释
sample_uid	样本唯一 ID。后续 features、labels、task dataset 都靠它对齐。
dataset	数据集名称，例如 XJTU-SY 或 PHM2012。
bearing_id	轴承 ID，例如 Bearing1_1。同一个轴承内部样本必须按时间顺序处理。
condition_id	工况 ID，例如转速和载荷组合 35Hz12kN。
source_group	PHM2012 中区分 Learning_set 与 Full_Test_Set；XJTU-SY 通常为空。

字段	解释
sample_id	原始文件编号或快照编号。
timestep	项目内部的时间顺序编号。它不一定是秒，但保证同一轴承内从早到晚递增。

4 数据集术语

4.1 XJTU-SY

XJTU-SY 是一个滚动轴承加速退化全寿命数据集，包含 15 个轴承，分为 3 个工况，每个工况 5 个轴承。项目中常用的划分方式是：同一工况下 5 个轴承，每次留 1 个轴承测试，其余轴承用于训练/验证。

名词	项目中的含义
35Hz12kN	转速约 35 Hz、载荷 12 kN 的工况。
Bearing1_1– Bearing1_5	该工况下的 5 个轴承。
fault_element	XJTU-SY 官方轴承级故障元素说明，例如 Outer Race Fault、Cage Fault。它不是逐样本标签。
xjtu_leave_one_bearing_out	同一工况下留一个轴承做测试的划分方式。

4.2 PHM2012 / PRONOSTIA

PHM2012 是 IEEE PHM 2012 Challenge 使用的 PRONOSTIA 轴承全寿命数据。它同样是 run-to-failure 数据，但不适合强行做故障类型识别，因为没有像 XJTU-SY 那样的官方轴承级 fault element 标签。

名词	项目中的含义
Learning_set	PHM2012 官方训练/学习集合。
Full_Test_Set	PHM2012 官方测试/验证集合。
acc_*.csv	加速度文件。当前框架读取最后两列作为水平、垂直振动。
temp_*.csv	温度文件。当前框架暂不纳入核心特征。
phm2012_official	优先按官方 train/test 结构划分。

5 标签、任务和目标变量

5.1 标签 label 是什么

在机器学习里，**标签**是模型要学习预测的目标。输入是特征，输出是标签。例如：

$$\text{特征} = [\text{RMS}, \text{kurtosis}, \text{spectral entropy}, \dots] \Rightarrow \text{标签} = \text{RUL 或健康状态}$$

轴承数据里，原始 CSV 通常没有每个快照的精确健康标签。因此项目用以下信息构造标签：

- 同一轴承内部的时间顺序。
- 轴承最终失效这一事实。
- 由特征构造的健康指标 HI。
- 由 HI 计算出的 FPT。
- XJTU-SY 的轴承级 fault element。

5.2 RUL: Remaining Useful Life

RUL 是 Remaining Useful Life，中文是**剩余使用寿命**。它回答：**从当前时刻到失效还剩多久？**

项目中有三种相关字段：

字段	解释
linear_rul_steps	线性 RUL 的剩余样本步数。越接近失效越小。
linear_rul_seconds	将剩余步数乘以样本间隔后的秒数。
linear_rul_norm	归一化到 [0, 1] 的线性 RUL，开始时接近 1，失效时为 0。
piecewise_rul_steps	分段 RUL 的剩余步数。FPT 前保持平台，FPT 后下降。
piecewise_rul_seconds	分段 RUL 的秒数版本。
piecewise_rul_norm	归一化到 [0, 1] 的分段 RUL，是 Stage 6 默认分析目标。

5.2.1 线性 RUL

如果一个轴承一共有 N 个样本，第 t 个样本的剩余步数为：

$$\text{linear_rul_steps}(t) = N - 1 - t$$

归一化后：

$$\text{linear_rul_norm}(t) = \frac{N - 1 - t}{N - 1}$$

直观理解：从第一天开始就认为寿命在均匀下降。这很简单，但有时不符合物理直觉，因为健康早期的振动可能长期稳定。

5.2.2 分段 RUL

分段 RUL 引入 FPT。FPT 前认为设备仍处于健康或稳定阶段，RUL 不明显下降；FPT 后才进入明显退化阶段：

$$\text{piecewise_rul_norm}(t) = \begin{cases} 1, & t < t_{\text{FPT}} \\ \frac{N-1-t}{N-1-t_{\text{FPT}}}, & t \geq t_{\text{FPT}} \end{cases}$$

这更接近项目的直觉：轴承不是从第一分钟就线性坏掉，而是先稳定运行，之后进入可观测退化。

5.3 退化 degradation

退化指设备健康程度随时间变差的过程。它不是某个单一标签，而是一个物理过程。退化通常表现为：

- 振动能量上升，例如 RMS、std、mean abs 变大。
- 冲击增强，例如 kurtosis、crest factor、impulse factor 增大。
- 频谱结构变化，例如 spectral centroid 或 entropy 改变。
- 不同健康阶段之间的分布逐渐错开。

项目通过 HI、FPT、RUL、健康状态、早期故障等多个对象来描述退化。

5.4 HI: Health Indicator

HI 是 Health Indicator，中文可称为**健康指标**。它把一个或多个特征转换成一条随时间变化的健康曲线，用来描述“轴承坏到什么程度”。

当前项目的 degradation_basic 使用 **feature-column HI**：

1. 优先选择 mag_time_rms，如果不存在则选择 h_time_rms，再不存在则选择 v_time_rms。
2. 如果 direction=bad_high，数值越大表示越坏；如果 bad_low，会取相反数。
3. 对同一轴承内的 HI 做滑动平均平滑，默认窗口为 3。
4. 对每个轴承单独做 min-max 归一化，得到 hi_norm。

用公式表示，若原始 HI 为 h_t ，平滑窗口为 $w = 3$ ：

$$\tilde{h}_t = \frac{1}{|\mathcal{W}_t|} \sum_{i \in \mathcal{W}_t} h_i$$

归一化为：

$$h_t^{\text{norm}} = \frac{\tilde{h}_t - \min(\tilde{h})}{\max(\tilde{h}) - \min(\tilde{h})}$$

重要注意：如果某个特征被用作 **HI source**，那么它在 **FPT**、健康状态、早期故障标签上表现好，存在循环定义风险。项目会在 `feature_ranking.csv` 和 `feature_cards.csv` 中标注 `is_label_source=true`。

5.5 FPT: First Predictable Time

FPT 是 First Predictable Time，中文可理解为**首次可预测时间**或**首次明显退化点**。它不是最终失效点，而是设备从“看起来健康”进入“退化已经可观测”的分界点。

通俗理解：

- FPT 前：信号基本像健康状态，模型很难可靠预测退化。
- FPT 后：退化趋势开始显现，RUL 预测和状态评估更有意义。

5.6 3σ 原则 / Three Sigma

当前项目用 3σ 原则检测 FPT。做法如下：

1. 取每个轴承前 `healthy_ratio=0.2` 的样本作为健康基线。
2. 计算健康基线 HI 的均值 μ 和标准差 σ 。
3. 阈值为：

$$\theta = \mu + 3\sigma + \Delta_{\min}$$

当前默认 `sigma_ratio=3.0`, `min_delta=0.0`。

4. 从前到后找连续 `consecutive_points=3` 个点都超过阈值的位置。
5. 第一个满足条件的位置就是 FPT。
6. 如果找不到，使用 `fallback`。当前默认 `fallback` 是 `healthy_ratio`，即健康段结束处。

为什么叫 3σ？如果健康期波动大致服从稳定分布，均值加 3 倍标准差以上通常属于很不寻常的偏离。连续多个点越过阈值，比单个点越过更稳健，可以减少偶然尖峰造成误报。

5.7 健康状态 Health State

健康状态是把轴承寿命阶段离散化。当前项目默认四类：

health_state_id	名称	含义
0	healthy	FPT 前，认为处于健康或稳定阶段。
1	slight	FPT 后早期退化，退化刚开始。
2	moderate	FPT 后中期退化，趋势更明显。
3	severe	FPT 后晚期退化，接近失效。

项目中，FPT 后的剩余退化过程按照进度比例切分。默认边界为 0.4 和 0.8：

$$\text{progress} = \frac{t - t_{\text{FPT}}}{N - 1 - t_{\text{FPT}}}$$

- $t < t_{\text{FPT}}$: healthy。
- $0 \leq \text{progress} < 0.4$: slight。
- $0.4 \leq \text{progress} < 0.8$: moderate。
- $\text{progress} \geq 0.8$: severe。

5.8 早期故障 Early Fault

早期故障检测在当前项目里是一个二分类标签：

$$\text{early_fault}(t) = \begin{cases} 0, & t < t_{\text{FPT}} \\ 1, & t \geq t_{\text{FPT}} \end{cases}$$

它回答的是：**当前样本是否已经进入 FPT 后的异常/退化阶段？**

注意它不是“故障已经严重”的意思。它更像是早期报警：一旦过了 FPT，就认为需要重点监控。

5.9 故障类型阶段 Fault Type Stage

fault type stage 是项目为 XJTU-SY 做的弱故障类型阶段标签。它结合健康状态和轴承级 fault element：

- 健康状态为 0：标为 normal。
- 中间退化阶段：标为 degraded_unknown。
- severe 阶段：使用 XJTU-SY 的轴承级 fault element，例如 outer race、inner race、cage 等。

PHM2012 不应强做 fault type，因为它没有同等的官方 fault element 标签。 当前分析配置中如果 PHM2012 缺少 fault_type_stage_name，会在 analysis_report.json 中记录 fault_type_skipped=true。

6 数据划分和泄漏

6.1 Train / Validation / Test

集合	作用
Train 训练集	用来拟合模型、估计标准化参数、做特征 ranking。
Validation 验证集	用来调参、早停、选择模型。

集合	作用
Test 测试集	只用于最终评估，不能用于选择特征或调参。

本项目特别强调：**特征选择、标准化参数、特征 ranking 应尽量只用 train split**。如果提前看 test label 来挑特征，结果会显得很好，但泛化评估不可信。

6.2 数据泄漏 Data Leakage

数据泄漏指模型或分析过程使用了本不应该提前知道的信息。例如：

- 用测试集均值和标准差标准化训练集。
- 用测试集标签挑选最好的特征。
- 用某个特征构造标签，又宣称同一个特征独立发现了该标签。

本项目最需要标注的是 **label-source leakage**。例如 mag__time__rms 被用作 HI source，FPT 和 early fault 标签又由 HI 构造，那么 mag__time__rms 在 early fault 上表现好并不意外。它仍可用，但论文和报告中必须说明。

7 原始信号、通道和特征命名

7.1 通道命名

当前 manual 特征使用三类通道：

通道	含义
h	horizontal，水平方向振动。
v	vertical，垂直方向振动。
mag	magnitude，水平和垂直的合成幅值，计算为 $\sqrt{h^2 + v^2}$ 。

7.2 特征列命名规则

manual 特征列遵循：

channel__domain__feature

例如：

- h__time__rms：水平通道的时间域 RMS。
- v__spectral__entropy：垂直通道的频域谱熵。
- mag__time__kurtosis：合成幅值通道的时间域峭度。

tsfresh 特征列遵循：

```
tsfresh\_\_kind\_\_calculator\_\_params
```

其中 kind 通常是 h 或 v，例如某个通道的均值、方差、FFT 系数、自相关等。

8 时间域特征

时间域特征直接在原始振动序列 $x_1, x_2, \dots, x_N$ 上计算。它们容易理解，适合向非专业读者解释。

8.1 manual_basic 当前启用的时间域特征

令 x_i 是一个快照内第 i 个振动采样点， N 是该快照采样点数， $|x_i|$ 是绝对值。

特征名	公式/定义	非专业解释与用途
mean	$\bar{x} = \frac{1}{N} \sum_i x_i$	平均振动偏置。若传感器零点偏移或信号不对称，mean 会变化。通常不是最强故障特征。
std	$\sqrt{\frac{1}{N} \sum_i (x_i - \bar{x})^2}$	振动离散程度。退化加剧时，振动波动通常更大，适合 RUL 和健康状态。
rms	$\sqrt{\frac{1}{N} \sum_i x_i^2}$	均方根，代表振动能量强度。轴承越坏，RMS 常越高，是最常用退化特征之一。
mean_abs	$\frac{1}{N} \sum_i x_i $	平均绝对振动幅值。比 mean 更能反映振动强度，适合 RUL 和健康状态。
ptp	$\max(x) - \min(x)$	peak-to-peak，峰峰值。反映一个快照内最大振动跨度，对冲击和严重退化敏感。
skewness	三阶标准化矩	偏度，描述波形是否向某一侧偏。可反映不对称冲击，但解释性弱于 RMS。
kurtosis	四阶标准化矩	峭度，描述尖峰/重尾程度。对局部冲击非常敏感，常用于早期故障检测。
crest_factor	$\frac{\max x_i }{\text{RMS}}$	峰值因子。看“最高尖峰”相对整体能量有多突出，适合发现突然冲击。
impulse_factor	$\frac{\max x_i }{\text{mean_abs}}$	脉冲因子。类似 crest factor，但以平均绝对幅值为基准，对尖峰敏感。
clearance_factor	$\frac{\max x_i }{(\frac{1}{N} \sum_i \sqrt{ x_i })^2}$	裕度因子。常用于滚动轴承冲击类故障，对尖锐冲击敏感。

8.2 代码支持但 manual_basic 未默认启用的时间域特征

特征名	解释
var	方差，等于 std 的平方，表示振动波动能量。
max	最大值，可能受单个异常点影响。
min	最小值，常与 max/ptp 配合理解。
shape_factor	RMS/mean_abs，形状因子，反映波形形态。

9 频域特征

频域特征先把时域信号通过 rFFT 转成频谱。频谱可以理解为：振动能量分布在哪些频率上。
对每个快照，项目计算一侧实数 FFT：

$$X_k = \text{rFFT}(x)_k, \quad P_k = |X_k|^2$$

其中 P_k 是第 k 个频率 bin 的功率。默认 include_dc=false，也就是去掉 0 Hz 的直流分量。

9.1 manual_basic 当前启用的频域特征

特征名	公式/定义	非专业解释与用途
centroid	$\sum_k f_k p_k$	频谱质心。把频谱看作质量分布，centroid 是能量中心频率。退化可能导致能量向高频或低频迁移。
bandwidth	$\sqrt{\sum_k (f_k - c)^2 p_k}$	频谱带宽。表示能量围绕质心分散得多宽。冲击和宽频噪声会影响它。
rms_frequency	$\sqrt{\sum_k f_k^2 p_k}$	RMS 频率。表示频率成分的均方根位置，常用于频率结构变化分析。
peak_frequency	$\arg \max_{f_k} P_k$	功率最大的频率。看当前最强的振动频率在哪里。
entropy	$-\sum_k p_k \log(p_k) / \log K$	谱熵。频谱越分散、越复杂，熵越高；频谱集中在少数频率时熵低。

这里 $p_k = P_k / \sum_j P_j$ 是归一化频谱功率， c 是 centroid。

9.2 代码支持但 manual_basic 未默认启用的频域特征

特征名	解释
flatness	谱平坦度。频谱越像白噪声，flatness 越高；越像单一尖峰，flatness 越低。

特征名	解释
rolloff	谱滚降频率。累计能量达到某个比例（默认 85%）时对应的频率。

10 manual_basic 的完整特征列

manual_basic 当前启用 3 个通道，每个通道 10 个时间域特征和 5 个频域特征，因此一共：

$3 \times (10 + 5) = 45$

个 manual 特征。

10.1 时间域 30 个特征列

通道	特征列
h	h__time__mean, h__time__std, h__time__rms, h__time__mean_abs, h__time__ptp, h__time__skewness, h__time__kurtosis, h__time__crest_factor, h__time__impulse_factor, h__time__clearance_factor
v	v__time__mean, v__time__std, v__time__rms, v__time__mean_abs, v__time__ptp, v__time__skewness, v__time__kurtosis, v__time__crest_factor, v__time__impulse_factor, v__time__clearance_factor
mag	mag__time__mean, mag__time__std, mag__time__rms, mag__time__mean_abs, mag__time__ptp, mag__time__skewness, mag__time__kurtosis, mag__time__crest_factor, mag__time__impulse_factor, mag__time__clearance_factor

10.2 频域 15 个特征列

通道	特征列
h	h__spectral__centroid, h__spectral__bandwidth, h__spectral__rms_frequency, h__spectral__peak_frequency, h__spectral__entropy
v	v__spectral__centroid, v__spectral__bandwidth, v__spectral__rms_frequency, v__spectral__peak_frequency, v__spectral__entropy
mag	mag__spectral__centroid, mag__spectral__bandwidth, mag__spectral__rms_frequency, mag__spectral__peak_frequency, mag__spectral__entropy

11 tsfresh 特征

tsfresh 是一个自动时间序列特征提取库。它会从时间序列中计算大量统计、频域、复杂度和自相关特征。项目提供：

- tsfresh_minimal：最小特征集合，速度快、解释简单。
- tsfresh_efficient：更丰富的特征集合，覆盖更多统计特征，但列数多、解释成本更高。
- manual_tsfresh_basic：manual 特征 + tsfresh minimal 的组合。

11.1 tsfresh minimal 的特征计算器

当前环境中 MinimalFCParameters 包含：

计算器	通俗解释
sum_values	所有采样点求和。
median	中位数。
mean	均值。
length	序列长度。
standard_deviation	标准差。
variance	方差。
root_mean_square	RMS。
maximum	最大值。
absolute_maximum	绝对值最大值。
minimum	最小值。

11.2 tsfresh efficient 的特征类型

EfficientFCParameters 当前包含 73 类计算器，其中许多计算器会展开成多个参数列。它覆盖：

- 基本统计：mean、median、variance、standard deviation、skewness、kurtosis。
- 能量和变化：abs energy、mean abs change、absolute sum of changes。
- 重复和计数：duplicate、value count、range count、count above/below mean。
- 自相关和局部相关：autocorrelation、partial autocorrelation、agg autocorrelation。
- 频域：FFT coefficient、FFT aggregated、Welch density、fourier entropy。
- 小波和峰值：cwt coefficients、number of peaks、number cwt peaks。
- 趋势和稳定性：linear trend、augmented Dickey-Fuller、large standard deviation。
- 复杂度和信息量：permutation entropy、Lempel-Ziv complexity、binned entropy。

非专业读者可以这样理解：manual 特征像是“人工挑选的少数可解释指标”；tsfresh 像是“自动生成的候选指标库”。tsfresh 可能找到有用信号，但每个特征的物理意义通常不如 RMS、kurtosis、spectral entropy 直观。

11.3 tsfresh efficient 当前计算器名称总览

下面列出项目当前环境中 EfficientFCParameters 的计算器名称。这里的“计算器”不是最终列名；很多计算器会因为不同参数组合展开成多列。例如 autocorrelation 会按多个 lag 展开，fft_coefficient 会按不同 coeff 和 attr 展开。

类别	计算器名称
基础统计	sum_values, median, mean, length, standard_deviation, variance, variation_coefficient, maximum, minimum, absolute_maximum, root_mean_square, skewness, kurtosis
重复与计数	has_duplicate, has_duplicate_max, has_duplicate_min, value_count, range_count, count_above, count_below, count_above_mean, count_below_mean, ratio_value_number_to_time_series_length

类别	计算器名称
极值位置	first_location_of_maximum, last_location_of_maximum, first_location_of_minimum, last_location_of_minimum, longest_strike_above_mean, longest_strike_below_mean
变化与能量	abs_energy, absolute_sum_of_changes, mean_abs_change, mean_change, mean_second_derivative_central, cid_ce, number_crossing_m, number_peaks, number_cwt_peaks, mean_n_absolute_max
分布与分位数	quantile, index_mass_quantile, large_standard_deviation, ratio_beyond_r_sigma, variance_larger_than_standard_deviation, symmetry_looking, benford_correlation
重复值统计	percentage_of_reoccurring_values_to_all_values, percentage_of_reoccurring_datapoints_to_all_datapoints, sum_of_reoccurring_values, sum_of_reoccurring_data_points
相关与自回归	autocorrelation, agg_autocorrelation, partial_autocorrelation, ar_coefficient, c3, time_reversal_asymmetry_statistic
频域与谱特征	fft_coefficient, fft_aggregated, spkt_welch_density, fourier_entropy
小波与局部形态	cwt_coefficients, change_quantiles
趋势与平稳性	linear_trend, agg_linear_trend, linear_trend_timewise, augmented_dickey_fuller
复杂度与信息量	binned_entropy, permutation_entropy, lempel_ziv_complexity, energy_ratio_by_chunks, query_similarity_count
非线性动力学	friedrich_coefficients, max_langevin_fixed_point

如果后续使用 tsfresh_efficient, 建议先用 Stage 6 的 feature_summary.csv 删除常数列和异常列, 再用 feature_ranking.csv 和 feature_cards.csv 选择少量稳定、可解释的特征。不要直接把上千列 tsfresh 特征全部放进论文解释中。

12 特征清洗和标准化

特征提取后，项目会进入 **FeatureCleaner**：

- 1. **median impute**：用训练集特征中位数填补 NaN/Inf。
- 2. **standard scale**：标准化为均值 0、标准差 1。
- 3. **drop constant**：删除训练集中几乎不变的常数特征。
- 4. **train-only fit**：中位数、均值、标准差只从训练集估计。

标准化公式：

$$z = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}}$$

标准化参数不能从测试集估计。 否则模型在训练阶段就“看见”了测试集分布，会导致评估乐观。

13 特征分析 Stage 6

Stage 6 的目标不是训练模型，而是回答：

- 哪些特征适合 RUL？
- 哪些特征适合健康状态？
- 哪些特征适合早期故障检测？
- 哪些特征只是末期突变，不适合早期检测？
- 哪些特征参与了 HI/FPT 标签构造，存在 label-source 风险？

Stage 6 的主要产物：

文件	含义
feature_summary.csv	每个特征的缺失、方差、均值、分位数、常数列检查。
rul_correlation.csv	特征与 RUL 的 Pearson/Spearman/Kendall 相关性。
degradation_scores.csv	单调性、鲁棒性、趋势一致性、末端一致性。
health_state_separability.csv	健康状态可分性，包括 MI、Fisher score、ANOVA F 和各状态均值/标准差。
early_fault_scores.csv	早期故障敏感性，包括 Cohen's d、AUC、FPT 前后均值差。
fault_type_scores.csv	故障类型阶段的弱可分性指标。
feature_ranking.csv	综合 ranking，包含 RUL/Health/Early/FaultType 分数和推荐任务。
feature_cards.csv	每个特征的解释卡片：物理意义、推荐任务、原因、caveat、泄漏标记。

文件	含义
feature_recommendations.md	面向读者的文字推荐报告。
figures/	特征曲线、箱线图、热图和任务推荐矩阵。

14 RUL 特征分析指标

RUL 关注：这个特征能不能稳定反映退化趋势？

14.1 相关性

项目计算 Pearson、Spearman、Kendall：

指标	解释
Pearson	线性相关。适合关系近似直线的特征。
Spearman	排序相关。只要一个特征随退化大致单调变化，即使不是直线，也能反映出来。
Kendall	排序一致性，更保守。

因为 RUL 越接近失效越小，而许多退化特征越接近失效越大，所以常见的是负相关。例如 RMS 上升、RUL 下降，Spearman 可能是 -0.85。因此 ranking 使用：

$$|\rho_{\text{Spearman}}|$$

14.2 退化行为分数

指标	解释
monotonicity	单调性。看同一轴承内特征是否主要朝一个方向变化。
robustness	鲁棒性。看特征曲线是否平滑、是否不容易被噪声支配。
trendability	趋势一致性。看不同轴承的特征曲线形状是否相似。
prognosability	末端一致性。看不同轴承临近失效时的特征值是否集中。

项目当前 RUL score：

$$\text{rul_score} = 0.35|\rho_s| + 0.25\text{monotonicity} + 0.20\text{robustness} + 0.20\text{trendability}$$

15 健康状态特征分析指标

健康状态关注：这个特征能不能区分 healthy / slight / moderate / severe？

指标	解释
mutual_information	互信息。衡量特征和健康状态之间的信息量，越高说明越有关联。
fisher_score	类间差异与类内波动的比值。类间越分开、类内越集中，分数越高。
anova_f	方差分析 F 值。判断不同健康状态的均值是否明显不同。
state_0_mean 等	每个健康状态下该特征的均值。可以看状态是否逐渐上移或下移。
state_0_std 等	每个健康状态下该特征的标准差。可以看每个状态内部是否稳定。

项目当前 health score：

$$\text{health_score} = 0.4 \cdot \text{MI} + 0.4 \cdot \text{Fisher} + 0.2 \cdot \text{ANOVA}$$

实际 ranking 前会对不同指标做归一化，避免量纲不一致。

16 早期故障检测指标

早期故障检测关注：FPT 前后是否已经能分开？

指标	解释
healthy_mean	FPT 前样本的特征均值。
fault_mean	FPT 后样本的特征均值。
mean_shift	FPT 后均值减去 FPT 前均值。
healthy_std	FPT 前波动。健康期波动太大，说明容易误报。
fault_std	FPT 后波动。异常期波动太大，说明状态不稳定。
cohens_d	两组均值差除以合并标准差，表示效应量。绝对值越大，两组越分开。
auc / auc_abs	ROC-AUC 的方向无关版本，max(AUC, 1 – AUC)。越接近 1 越容易区分。

项目当前 early fault score：

$$\text{early_fault_score} = 0.5|\text{Cohen's } d| + 0.5 \cdot \text{AUC}_{\text{effective}}$$

17 故障类型特征分析

当前阶段的 fault type 分析是弱版本，因为还没有加入 BPFO/BPFI/BSF/FTF 等轴承机理频率特征。现阶段只能用 manual/tsfresh 统计特征去看它们是否能弱区分：

```
normal, degraded_unknown, outer/inner/cage/compound
```

这可以作为探索，但不能过度解释为“已经识别了具体故障机理”。真正的故障机理解释后续应加入：

- BPFO energy：外圈故障特征频率能量。
- BPFI energy：内圈故障特征频率能量。
- BSF energy：滚动体故障特征频率能量。
- FTF energy：保持架故障特征频率能量。
- envelope spectrum peak：包络谱峰值。
- harmonic/sideband energy：谐波和边带能量。

18 哪些特征通常适合哪些任务

特征族	常适合任务	原因和注意事项
rms, std, mean_abs	RUL、HealthState	代表整体振动能量，退化时通常稳定上升。若被用作 HI source，需要标注泄漏风险。
ptp	HealthState、EarlyFault	对峰值跨度敏感，严重退化和冲击会增大，但可能受异常点影响。
kurtosis	EarlyFault	对局部冲击敏感，适合发现早期缺陷，但不一定单调，不一定适合 RUL 主特征。
crest_factor	EarlyFault	看尖峰相对 RMS 是否突出，适合突发冲击检测。
impulse_factor	EarlyFault	看尖峰相对平均绝对幅值是否突出，噪声敏感。
clearance_factor	EarlyFault	轴承故障中常用的冲击敏感指标，解释时要结合曲线。
spectral_centroid	RUL、HealthState	反映频谱能量中心迁移，但可能受工况变化影响。
rms_frequency	RUL、HealthState	反映整体频率结构变化。

特征族	常适合任务	原因和注意事项
spectral_entropy	HealthState、EarlyFault	反映频谱复杂度或宽频激励，解释性不如 RMS 直观。
tsfresh_abs_energy 等能量特征	RUL	能量类特征通常与退化相关，但需要跨轴承验证。
tsfresh_kurtosis 等 冲击特征	EarlyFault	对尖峰和冲击敏感，但噪声风险高。

19 如何阅读分析结果

建议按以下顺序看：

- 1. 看 `analysis_report.json`: 确认 `ok=true`、`fit_scope=train_only`、是否有 `leakage warning`、PHM2012 是否跳过 `fault type`。
- 2. 看 `feature_summary.csv`: 先排除 NaN 多、Inf 多、常数列、方差极小的特征。
- 3. 看 `feature_ranking.csv`: 分别按 `rank_rul`、`rank_health`、`rank_early_fault` 排序。
- 4. 看 `feature_cards.csv`: 理解每个特征的物理意义、适合任务、原因和 `caveat`。
- 5. 看 `feature_recommendations.md`: 快速获得每类任务推荐特征。
- 6. 看 `figures/`: 用曲线和箱线图人工确认，不要只相信分数。

20 常见误解澄清

误解	正确理解
“加速度值”和“振动值”是不是两个东西？	在本项目语境里，原始 CSV 的最后两列是振动加速度信号。口语里说振动值，通常就是指这些加速度采样值。
RUL 是真实标签吗？	对 run-to-failure 数据，可根据最终失效时间构造 RUL；但 piecewise RUL 依赖 FPT，是一种任务标签设计。
FPT 是官方标签吗？	不是。当前 FPT 是项目用 HI 和 3σ 规则计算出的退化起点。
healthy / slight / moderate / severe 是原始数据给的吗？	不是逐样本官方标签，而是项目基于 FPT 和退化进度构造的健康状态标签。
early fault 是不是严重故障？	不是。当前 early fault 表示已经过 FPT，进入可观测异常阶段。
RMS 排名高就证明 RMS 独立发现故障吗？	不一定。如果 RMS 被用来构造 HI/FPT，就必须说明 label-source 风险。

误解	正确理解
test set 能不能用来挑特征?	不应该。特征 ranking 应使用 train split, 否则评估不可信。
PHM2012 能不能做 fault type?	当前不主打, 因为缺少 XJTU-SY 那种轴承级 fault element 标签。

21 本项目命令示例

XJTU-SY 上运行完整特征分析:

```
uv run bp --config-name smoke \
  mode=analyze_features \
  dataset=xjtu_sy \
  split=xjtu_leave_one_bearing_out \
  feature>manual_basic \
  label=degradation_basic \
  analysis=full_feature_analysis \
  dataset.root=/Users/nev8r/Desktop/phm2/data/loader_roots/xjtu \
  split.condition_id=35Hz12kN \
  split.test_bearing_id=Bearing1_5 \
  split.val_bearing_id=Bearing1_4
```

运行后重点查看:

```
artifacts/runs/<run_id>/analysis/feature_ranking.csv
artifacts/runs/<run_id>/analysis/feature_cards.csv
artifacts/runs/<run_id>/analysis/feature_recommendations.md
artifacts/runs/<run_id>/analysis/figures/
```

22 缩写表

缩写	全称	中文解释
PHM	Prognostics and Health Management	故障预测与健康管理
RUL	Remaining Useful Life	剩余使用寿命
HI	Health Indicator	健康指标
FPT	First Predictable Time	首次可预测时间/首次明显退化点
FFT	Fast Fourier Transform	快速傅里叶变换

缩写	全称	中文解释
rFFT	Real-input FFT	实数输入的一侧 FFT
RMS	Root Mean Square	均方根
STD	Standard Deviation	标准差
PTP	Peak-to-Peak	峰峰值
AUC	Area Under ROC Curve	ROC 曲线下面积
MI	Mutual Information	互信息
ANOVA	Analysis of Variance	方差分析
BPFO	Ball Pass Frequency Outer Race	外圈故障特征频率
BPFI	Ball Pass Frequency Inner Race	内圈故障特征频率
BSF	Ball Spin Frequency	滚动体自转故障频率
FTF	Fundamental Train Frequency	保持架故障特征频率

23 一句话总结

本项目的核心思想是：把轴承全寿命振动信号转换成可解释的时间域和频域特征，再用 HI 和 FPT 构造 RUL、健康状态和早期故障标签，最后通过 train-only 的特征分析判断哪些特征适合寿命预测、哪些适合状态评估、哪些适合早期报警，并明确标注标签来源风险，避免把由标签构造带来的优势误当成独立发现能力。