

轴承预测性维护中的剩余寿命预测与故障分析

USTC/SSE BearingPrediction 项目组

2026 年 6 月 22 日

目录

摘要	3
1 绪论	4
1.1 研究背景	4
1.2 总体技术路线	4
1.3 本文工作	4
2 任务与数据集	5
2.1 三任务定义	5
2.2 数据集	5
2.3 划分原则	6
3 数据处理流程	6
3.1 从原始信号到任务样本	6
3.2 训练集拟合原则	6
3.3 任务数据形态	6
4 特征分析	7
4.1 manual_basic 特征族	7
4.2 任务级分析方法	7
4.3 推荐矩阵	8
4.4 RUL 与早期故障的代表图	8
5 标签构造	10
5.1 RUL 标签	10
5.2 HealthState 标签	10
5.3 EarlyFault 标签	10
5.4 标签源特征说明	10

目录	2
6 模型方法	11
6.1 表格基线模型	11
6.2 GRU 序列基线	11
6.3 论文复现实验模型	11
7 实验设置	12
7.1 主线设置	12
7.2 对照实验设置	12
7.3 演示训练设置	14
8 实验结果	14
8.1 主结果表	14
8.2 XJTU-SY RUL 结果	16
8.3 XJTU-SY EarlyFault 结果	17
8.4 PHM2012 结果	18
8.5 结果小结	20
9 论文复现实验	20
9.1 定位	20
9.2 PHM2012 RUL 的 CAM-LSTM 复现模型	21
9.3 XJTU-SY 故障诊断复现模型	22
9.4 与本文方法实验的关系	23
10 演示视频	23
10.1 视频内容	23
10.2 视频截图	24
10.3 演示与主线结果的边界	24
11 不足与展望	25
11.1 当前不足	25
11.2 未来工作	25
12 结论	25

摘要

轴承是旋转机械中最常见、也最容易影响整机可靠性的关键部件。为了在失效前完成维护决策,预测性维护不仅需要判断轴承是否已经故障,还需要估计剩余寿命、识别退化阶段,并尽早发现异常趋势。本文围绕 XJTU-SY 和 PHM2012 两个轴承振动数据集,构建了一个覆盖数据加载、特征分析、标签构造、任务数据集、模型训练、对照实验和演示视频的完整实验闭环。

本文将任务统一为三个层次:剩余寿命预测、健康阶段识别和早期故障检测。其中,剩余寿命预测统一采用 `linear_rul_norm` 作为目标, `HealthState` 和 `EarlyFault` 则基于退化过程构造伪标签。特征侧采用 `manual_basic` 特征族,覆盖时域幅值、高阶统计、频域形状、频域复杂度、频带能量和合成幅值通道,并通过相关性、趋势性、阶段可分性和早期故障效应分析筛选任务适配特征。模型侧先完成 MLP、XGBoost、RandomForest 等表格基线,再以长度为 8 的特征序列作为输入训练 GRU 序列基线。最终主线结果来自六个 200ep GRU 序列实验;两个 50ep 加速视频仅用于展示训练过程。

实验结果表明,GRU 序列基线在 XJTU-SY `EarlyFault` 上取得 `test WeightedF1 = 0.851679`,在 PHM2012 `EarlyFault` 上取得 `test WeightedF1 = 0.682715`;RUL 任务在 XJTU-SY 和 PHM2012 上分别取得 `test RMSE = 0.275009` 和 `0.280362`。与此同时,预测质量排查也显示 RUL 泛化仍是主要难点,尤其在跨轴承、跨工况条件下不应过度夸大预测精度。除本文方法实验外,本文还整理了 PHM2012 RUL 的 CAM-LSTM 复现模型和 XJTU-SY 故障诊断复现模型,用于说明典型论文方法的复现实验能力,但不将其混入本文统一三任务主结果。

1 绪论

1.1 研究背景

滚动轴承承担支撑旋转轴、降低摩擦和传递载荷的作用，广泛存在于电机、泵、风机、机床和车辆等装备中。轴承一旦发生局部剥落、磨损或润滑异常，振动信号会最先出现幅值、冲击和频率结构变化。PHM2012 预测挑战数据集正是围绕这类全寿命振动信号构建的典型寿命预测场景 [1]。如果这些变化没有被及时识别，局部故障可能进一步扩展为停机、连锁损伤甚至安全事故。因此，轴承预测性维护的目标不是等到故障已经明显发生后再报警，而是在退化早期识别风险，并为维护计划提供剩余寿命估计。

传统故障诊断通常把问题简化为“正常或故障”的分类任务，这对已发生故障的识别有效，但对维护决策还不够。工程人员还需要知道三个更细的问题：当前轴承还能运行多久、当前处于哪个退化阶段、是否已经进入早期异常状态。因此，本文采用 RUL、HealthState 和 EarlyFault 三任务框架，将寿命预测、状态识别和早期预警统一到同一套数据与模型流程中。

1.2 总体技术路线

图 1 给出本文的总体问题链条。轴承退化首先改变原始振动信号，随后这些变化会反映到幅值统计、冲击强度、频谱分布和能量结构中。模型并不直接面对“故障”这个抽象概念，而是通过特征和标签把退化过程转化为可学习的监督任务。




图 1: 轴承退化到三任务建模的关系

1.3 本文工作

本文的主要工作包括：

1. 建立 XJTU-SY 与 PHM2012 两个数据集的统一加载、索引和划分流程，避免同一轴承时间片泄漏到不同数据子集。
2. 构造 RUL、HealthState 和 EarlyFault 三类任务标签，其中 RUL 统一采用 `linear_rul_norm`。
3. 对 `manual_basic` 特征族进行任务级分析，解释不同特征对寿命预测和故障预警的作用。

4. 训练 MLP、XGBoost、RandomForest 和 GRU 序列基线，并以 GRU 200ep 结果作为本文方法实验主线。
5. 整理论文复现实验，包括 PHM2012 RUL 的 CAM-LSTM 复现模型和 XJTU-SY 故障诊断复现模型。
6. 制作两个 50ep 加速训练过程视频，展示训练过程和结果图，服务于最终答辩演示。

2 任务与数据集

2.1 三任务定义

本文将轴承预测性维护拆分为三个互补任务，如表 1 所示。RUL 关注连续寿命趋势，HealthState 关注退化阶段，EarlyFault 关注是否已经进入预警状态。三个任务的共同点是都来自同一条轴承时间序列；区别在于输出形式、评价指标和工程含义不同。

表 1: 三任务定义

任务	输出	类型	主要指标	工程作用
RUL	<code>linear_rul_norm</code>	回归	RMSE	预测当前样本距离寿命终点的归一化剩余比例。
HealthState	<code>health_state_id</code>	四分类	WeightedF1	将退化过程划分为健康、轻微退化、中度退化和严重退化阶段。
EarlyFault	<code>early_fault</code>	二分类	WeightedF1	判断样本是否进入早期异常或早期故障预警阶段。

RUL 的目标值为 `linear_rul_norm`。该目标用 1 表示寿命早期，用 0 表示寿命终点，中间按时间顺序线性下降。HealthState 和 EarlyFault 不是数据集原始给出的人工故障类别，而是根据退化过程和 FPT 等规则构造的伪标签。因此，分类结果在论文中应解释为“退化阶段识别”和“早期预警能力”，不能等同于人工拆检得到的真实故障类型标签。

2.2 数据集

本文使用 XJTU-SY 与 PHM2012 两个轴承振动数据集。二者都包含轴承从正常运行到失效附近的振动信号，但实验语义不同。XJTU-SY 更强调多工况条件下的全寿命退化过程，PHM2012 更强调预测挑战中的学习集和测试集划分。表 2 总结了两个数据集在本文中的使用方式。

表 2: 数据集与实验划分语义

数据集	数据特点	划分方式	使用目的
XJTU-SY	多工况、全寿命轴承振动数据，包含不同转速和载荷条件。	按轴承划分训练、验证和测试，避免同一轴承时间片泄漏。	检验跨轴承和多工况条件下的特征与模型泛化能力。
PHM2012	预测挑战数据集，包含学习集和测试集，常用于轴承寿命预测。	优先遵循官方学习集和测试集语义，并保持轴承内部时间顺序。	检验方法在经典 PHM 预测任务上的表现。

2.3 划分原则

为了避免信息泄漏，本文以轴承为基本划分单位。也就是说，同一轴承的连续时间片不会同时出现在训练、验证和测试数据中。对于序列样本，窗口长度设置为 8，只在同一轴承和同一数据子集内部构造，不跨轴承、不跨数据子集拼接。这一点对 RUL 特别重要，因为相邻时间片之间高度相关，如果随机打散，会造成模型提前看到测试轴承的退化轨迹。

在 XJTU-SY 上，实验重点是跨轴承和多工况下的泛化能力。在 PHM2012 上，实验优先保留官方学习集与测试集的语义。后续所有结果解释都遵循这一划分逻辑。

3 数据处理流程

3.1 从原始信号到任务样本

原始振动信号不能直接作为最终表格模型输入。本文将每个振动快照视作一个样本，先从水平、垂直和合成幅值通道中提取 `manual_basic` 特征，再根据训练集统计量完成缺失值填充、标准化和常量特征过滤。标签侧通过退化过程构造 RUL、HealthState 和 EarlyFault 三类目标。最终，表格模型使用单个样本特征，GRU 序列基线则使用连续 8 个样本组成的特征序列。




图 2: 数据处理与建模流程

3.2 训练集拟合原则

标准化参数、缺失值填充值和常量特征判断只从训练集估计，然后应用到验证集和测试集。这样做可以避免测试轴承的信息进入训练过程。该原则同样适用于序列样本：先在样本级完成特征清洗，再按时间顺序构造长度为 8 的序列。

3.3 任务数据形态

最终任务数据有两种形态：

- 表格样本：每个样本对应一个振动快照的特征向量，供 MLP、XGBoost 和 RandomForest 使用。
- 序列样本：每个样本由连续 8 个特征向量组成，供 GRU 序列基线使用。

这一区分很重要。表格样本只描述某一时刻的振动状态，而序列样本能够显式包含退化过程中的短期变化趋势，更接近 RUL 和早期预警任务的时间属性。

4 特征分析

4.1 manual_basic 特征族

本文使用 manual_basic 作为最终主线特征集。该特征集不是简单堆叠统计量，而是围绕轴承振动退化的可解释信号变化构造。特征筛选、推荐矩阵和泄漏检查来自项目特征分析报告 [4]。表 3 总结了主要特征族及其含义。

表 3: manual_basic 特征族及解释

特征族	代表特征	物理或统计含义
时域幅值特征	RMS、mean_abs、std、ptp	反映振动能量、波动幅度和冲击强度，是退化过程中最直观的统计特征。
高阶统计特征	kurtosis、skewness	反映冲击尖锐程度和分布偏斜程度，对早期局部故障较敏感。
频域形状特征	spectral centroid、bandwidth	描述能量在频率轴上的中心位置和扩散程度。
频域复杂度特征	spectral entropy	描述频谱能量分布是否分散，用于观察退化后信号复杂度变化。
频带能量特征	band energy	汇总不同频段的能量变化，帮助捕捉频率结构变化。
合成幅值通道	mag 通道特征	将水平和垂直通道合成为整体幅值，用于减少方向差异带来的不稳定。

其中 RMS、mean_abs、std 和 ptp 通常反映振动幅值和能量变化；kurtosis 与 skewness 对冲击和非对称分布敏感；spectral centroid、bandwidth 和 spectral entropy 则描述频谱重心、频带扩散和频谱复杂度。合成幅值通道 mag 用于同时利用水平和垂直方向信息，但当 mag__time__rms 参与 HI/FPT 构造时，需要在最终模型中谨慎处理其标签源争议。

4.2 任务级分析方法

不同任务需要不同证据：

- RUL：关注特征与寿命比例的相关性、单调性和退化趋势。
- HealthState：关注不同退化阶段之间的特征分布是否可分。
- EarlyFault：关注正常阶段与早期异常阶段之间的效应差异。

因此，特征分析报告同时使用 RUL 相关性、退化行为分数、健康阶段箱线图、早期故障效应图和推荐矩阵，而不是只输出一个总分表。

4.3 推荐矩阵

图 3 和图 4 展示了两个数据集上的推荐特征矩阵。矩阵的作用是把“特征是否有用”落到具体任务上：某些特征对 RUL 的趋势预测更重要，另一些特征对 EarlyFault 的前后状态差异更敏感。




图 3: XJTU-SY 三任务推荐特征矩阵




图 4: PHM2012 三任务推荐特征矩阵

4.4 RUL 与早期故障的代表图

图 5 给出 XJTU-SY 上 RUL 相关特征排序，用于观察哪些特征随寿命推进呈现更稳定的变化。图 6 给出 PHM2012 上早期故障效应，用于观察故障前后哪些特征差异更明显。




图 5: XJTU-SY RUL 相关特征排序




图 6: PHM2012 EarlyFault 特征效应

图 7 进一步展示了健康阶段之间的特征分布差异。箱线图能够帮助判断 HealthState 任务为什么比 EarlyFault 更难：四阶段划分要求模型区分更细的退化等级，而不同轴承之间的分布差异会削弱阶段边界。




图 7: XJTU-SY 健康阶段特征箱线图

5 标签构造

5.1 RUL 标签

本文最终采用 `linear_rul_norm` 作为 RUL 目标。对于每条轴承寿命序列，寿命早期目标值接近 1，寿命终点目标值接近 0，中间按照样本时间顺序线性下降。这样做的好处是定义直观、跨数据集一致，并且不会在寿命早期人为制造长时间常数平台。

此前探索过的非线性或分段式 RUL 构造不作为本文主线结果。最终报告、表格和图像均以 `linear_rul_norm` 为准。

5.2 HealthState 标签

HealthState 将退化过程划分为四个阶段：

- 0：健康阶段。
- 1：轻微退化阶段。
- 2：中度退化阶段。
- 3：严重退化阶段。

该标签来自退化过程和 FPT 之后的阶段划分，因此属于伪标签。它的价值在于提供比二分类更细的退化状态描述；风险在于阶段边界并非人工拆检确认，因此实验结论应称为健康阶段识别，而不是严格故障类型诊断。

5.3 EarlyFault 标签

EarlyFault 是二分类标签：

- 0：未进入早期异常阶段。
- 1：进入早期异常或早期故障预警阶段。

与 HealthState 相比，EarlyFault 只要求区分“是否进入预警阶段”，因此边界更粗、任务更稳定。这也是后续实验中 EarlyFault 表现通常优于 HealthState 的重要原因。

5.4 标签源特征说明

`mag_time_rms` 在 HI/FPT 构造中起到参考作用，因此当它同时作为模型输入时，可能引发标签源泄漏争议。本文方法实验尽量使用 `non-label-source` 特征子集；对于需要全量人工特征的 RUL 实验，也明确排除该参考特征或在结果中标注其风险。这样可以让特征分析、标签构造和模型评估保持清晰边界。

6 模型方法

6.1 表格基线模型

表格基线模型用于回答一个基础问题：窗口级人工特征是否已经足以完成三任务建模。本文使用 MLP 作为基础表格神经网络基线，并使用 XGBoost 与 RandomForest 作为传统表格对照模型。MLP 能验证简单神经网络对特征表的建模能力；XGBoost 和 RandomForest 则用于检查树模型是否能从少量强特征中得到稳健表现。

对照模型实验不作为最终主线模型，而是用于解释模型选择边界。例如，树模型在 EarlyFault 上表现接近 GRU，但在 RUL 上容易出现训练集极好、验证和测试退化明显的现象，这说明寿命预测不能只依赖单点表格特征。

6.2 GRU 序列基线

GRU 序列基线是本文方法实验的主线模型。它的输入不是单个振动快照，而是同一轴承内连续 8 个窗口级特征向量。GRU 编码器读取该特征序列，最后时刻隐状态进入任务 head：RUL 使用 1 维回归输出，HealthState 使用 4 类 logits，EarlyFault 使用 2 类 logits。结构如图 8 所示。




图 8: GRU 序列基线结构

GRU 的优势在于能够利用退化过程的局部时间顺序。对 RUL 来说，相邻样本之间的变化趋势比单个时刻的绝对值更重要；对 EarlyFault 来说，异常出现前后的短期变化也有助于提升识别能力。

6.3 论文复现实验模型

本文还整理了两类论文复现实验模型。第一类是用于 PHM2012 RUL 的 CAM-LSTM 复现模型，它属于寿命预测复现实验。第二类是用于 XJTU-SY 故障诊断的 ResCNN-LSTM 复现模型，它属于故障诊断复现实验。这两类模型只用于展示典型论文方法的复现实验能力，不替代本文统一三任务框架，也不参与 HealthState 任务结论。

7 实验设置

7.1 主线设置

本文方法实验以 GRU 序列基线为主线。核心设置如下：

- 输入模式：feature sequence。
- 序列长度：8。
- 特征集：manual_basic，根据任务使用 full 或 compact 子集。
- RUL 目标：linear_rul_norm。
- 分类目标：health_state_id 和 early_fault。
- 训练轮数：200ep。
- batch size：64。
- 评价指标：RUL 使用 RMSE；分类任务使用 Accuracy、MacroF1 和 WeightedF1，其中 WeightedF1 作为主要指标。

所有序列样本均在同一轴承和同一数据子集内部构造，不跨轴承、不跨数据子集。标准化和清洗参数只从训练集估计。

7.2 对照实验设置

对照模型包括 MLP、XGBoost 和 RandomForest。它们主要使用窗口级表格特征，不显式建模时间序列。对照实验的作用是判断 manual_basic 特征本身的建模能力，以及传统表格模型相对于 GRU 序列基线的优势和不足。

表 4: 对照模型实验的代表性结果

数据集	任务	模型	指标	测试集结果	结论 口径
XJTU-SY	RUL	RandomForest	RMSE	0.399658	优于默认MLP, 但RUL仍有明显分布偏移风险。
XJTU-SY	EarlyFault	XGBoost	WeightedF1	0.839369	接近GRU序列基线, 可作为强表格对照。
PHM2012	RUL	RandomForest	RMSE	0.337575	优于默认MLP, 但弱于GRU序列基线。
PHM2012	EarlyFault	RandomForest	WeightedF1	0.613220	可作为对照结果, 但不是最终主线模型。

7.3 演示训练设置

两个演示视频使用 50ep 训练过程，只用于展示训练过程中的 epoch 变化、train_loss 变化和日志滚动。它们不是最终指标来源。本文所有主线指标均来自 200ep GRU 序列实验。

8 实验结果

8.1 主结果表

表 5 展示了两个数据集、三个任务上的 GRU 200ep 主线结果。这些指标来自已归档的 GRU 序列基线结果 [6]。可以看到，EarlyFault 是当前表现最稳定的任务，尤其是 XJTU-SY；RUL 能形成一定寿命趋势，但仍需要结合分轴承曲线和残差图谨慎解释；HealthState 四阶段伪标签任务最难，结果明显低于 EarlyFault。

表 5: GRU 序列基线 200ep 主线结果

数据集	任务	目标	指标	测试集结果	解读
XJTU-SY	RUL	linear_rul_norm	RMSE	0.275009	能形成连续寿命趋势，但跨轴承泛化仍需谨慎。
XJTU-SY	HealthState	health_state_id	WeightedF1	0.375525	四阶段伪标签较难，结果反映任务复杂性。
XJTU-SY	EarlyFault	early_fault	WeightedF1	0.851679	当前最稳定的正向分类结果。
PHM2012	RUL	linear_rul_norm	RMSE	0.280362	在官方语义划分下可展示寿命趋势。
PHM2012	HealthState	health_state_id	WeightedF1	0.417599	伪标签阶段识别仍有明显提升空间。
PHM2012	EarlyFault	early_fault	WeightedF1	0.682715	能提供早期异常识别能

8.2 XJTU-SY RUL 结果

图 9 展示了 XJTU-SY RUL 的分轴承预测曲线。图 10 展示预测值与真实值的散点关系。两张图共同说明：GRU 序列基线能够学习到寿命下降趋势，但不同轴承之间仍存在明显误差差异，这也是本文在 RUL 结论中保持保守口径的原因。




图 9: XJTU-SY GRU RUL 分轴承预测曲线




图 10: XJTU-SY GRU RUL 预测值与真实值散点图

8.3 XJTU-SY EarlyFault 结果

图 11 展示了 XJTU-SY EarlyFault 的混淆矩阵。该任务 test WeightedF1 = 0.851679，是当前本文方法实验中最适合作为正向展示的分类结果。它说明，基于特征序列的 GRU 能够较好地地区分正常阶段和早期异常阶段。




图 11: XJTU-SY GRU EarlyFault 混淆矩阵

8.4 PHM2012 结果

PHM2012 上, RUL 的 test RMSE = 0.280362, EarlyFault 的 test WeightedF1 = 0.682715。图 12 给出 RUL 分轴承预测曲线, 图 13 给出 EarlyFault 混淆矩阵。PHM2012 的任务难点在于官方语义划分下测试轴承差异较大, 因此模型表现应解释为当前框架下的可复查基线, 而不是最终工业部署精度。




图 12: PHM2012 GRU RUL 分轴承预测曲线




图 13: PHM2012 GRU EarlyFault 混淆矩阵

8.5 结果小结

综合表格和图像，本文方法实验得到三个结论：

1. EarlyFault 是当前最稳定的任务，说明人工特征和 GRU 序列对早期异常识别有效。
2. RUL 能形成趋势预测，但跨轴承差异仍然明显，需要未来加入物理频率特征和更强序列模型。
3. HealthState 由于阶段数更多且标签为退化伪标签，当前结果一般，应作为阶段识别探索而非强结论。

9 论文复现实验

9.1 定位

论文复现实验用于说明项目具备复现典型论文方法的能力。它与本文统一三任务框架互补，但不混为同一实验。具体来说，PHM2012 RUL 的 CAM-LSTM 复现模型对应 Sun 等人的 RUL 预测方法 [3]；XJTU-SY 故障诊断复现模型对应 Qiao 等人的故障诊断对照思路 [2]。二者都不参与 HealthState 任务结论。

表 6: 论文复现实验结果

复现实验	模型	数据集	指标	说明
RUL 复现	CAM-LSTM 复现模型	PHM2012	RMSE = 0.146737, MAE = 0.105007, R2 = 0.733183	用于验证典型寿命预测论文模型的复现实验流程。
故障诊断复现	ResCNN-LSTM 复现模型	XJTU-SY	Accuracy = 0.997072, WeightedF1 = 0.997072	用于验证典型故障诊断模型的复现实验流程。

9.2 PHM2012 RUL 的 CAM-LSTM 复现模型

图 14 展示了 RUL 复现模型结构，图 15 展示了分轴承预测曲线。该复现实验 test RMSE = 0.146737, MAE = 0.105007, R2 = 0.733183。该结果说明，在相应论文设置下，CAM-LSTM 复现模型能够取得较强的寿命预测表现。

CBAM-CNN-LSTM RUL regression




图 14: PHM2012 RUL 的 CAM-LSTM 复现模型结构




图 15: PHM2012 CAM-LSTM 复现模型分轴承预测曲线

9.3 XJTU-SY 故障诊断复现模型

图 16 展示了故障诊断复现模型结构，图 17 展示混淆矩阵。该复现实验 test Accuracy = 0.997072, WeightedF1 = 0.997072, 说明在相应二分类故障诊断设置下，复现模型表现很强。




图 16: XJTU-SY 故障诊断复现模型结构




图 17: XJTU-SY 故障诊断复现模型混淆矩阵

9.4 与本文方法实验的关系

论文复现实验回答“典型论文模型是否能够在本项目中复现”的问题；本文方法实验回答“统一三任务框架下，特征分析和 GRU 序列模型能否形成可复查基线”的问题。二者数据处理、任务定义和目标并不完全相同，因此不能直接把复现实验指标当作本文三任务结果。最终答辩中应将其放在“复现实验对照”章节，而不是放入 GRU 主结果表。

10 演示视频

10.1 视频内容

本文整理了两个中文加速训练过程视频，如表 7 所示。视频目标是展示训练过程可视化，而不是替代实验结果表。视频资产与筛选规则来自最终答辩资产清单 [5]。视频中可以看到 epoch 递增、train_loss 变化和日志滚动；结尾展示对应任务的结果图。

表 7: 训练过程演示视频

视频	任务	轮数	用途
XJTU-SY GRU 加速训练视频	RUL RUL	50ep	展示训练过程中的 epoch、train_loss 和日志滚动，结果指标不取自该演示 run。
XJTU-SY Early-Fault GRU 加速训练视频	EarlyFault EarlyFault	50ep	展示分类任务训练过程和结尾结果图，最终结论仍引用 200ep 结果。

10.2 视频截图

图 18 展示 RUL 训练过程截图，图 19 展示 EarlyFault 视频结尾的结果图截图。结果页不展示训练曲线，避免把训练过程曲线误认为模型效果图。



图 18: XJTU-SY RUL GRU 加速训练过程截图



图 19: XJTU-SY EarlyFault GRU 演示视频结果图截图

10.3 演示与主线结果的边界

两个视频均为 50ep 演示训练，用于说明系统能够动态展示训练过程。本文所有主线指标仍来自 200ep GRU 序列实验。这样处理可以同时满足答辩展示的可视化需求和实验结论的严谨

性。

11 不足与展望

11.1 当前不足

本文已经完成从数据到演示的完整实验闭环，但仍存在以下限制：

1. RUL 泛化仍是主要难点。跨轴承和跨工况差异会导致预测曲线偏移，部分早期模型甚至不能稳定超过 naive baseline，因此 RUL 结论必须保守。
2. HealthState 和 EarlyFault 是基于退化过程构造的伪标签，不等同于人工拆检或专家标注的真实故障类型。
3. 当前特征主要是人工统计特征，尚未充分加入 BPFO、BPFI、BSF、FTF 等物理故障频率特征。
4. tsfresh 在全量长信号上存在资源压力，需要后续设计批处理、降采样或窗口级压缩方案。
5. 当前训练没有做完整超参数搜索，GRU 结构、学习率、正则化和序列长度仍有优化空间。
6. 论文复现实验和本文统一三任务框架不是同一实验设置，不能简单横向比较全部指标。

11.2 未来工作

后续可以从五个方向改进：

- 引入物理故障频率特征，将轴承几何参数和转速信息纳入频域分析。
- 比较更强的时序模型，例如 LSTM、TCN、Transformer 或注意力机制模型。
- 设计多任务联合学习，让 RUL、HealthState 和 EarlyFault 共享退化表示。
- 增加跨工况训练和跨数据集迁移实验，检验模型在更强分布偏移下的鲁棒性。
- 引入不确定性估计，避免只给出单点寿命预测而缺少置信度表达。

这些方向能够进一步提升方法的工程可信度，也能让本文框架从课程结题实验走向更完整的 PHM 研究系统。

12 结论

本文围绕轴承预测性维护，完成了 XJTU-SY 和 PHM2012 两个数据集上的三任务实验闭环。通过统一的数据加载、按轴承划分、manual_basic 特征分析、linear_rul_norm 标签构造和 GRU 序列基线训练，本文将剩余寿命预测、健康阶段识别和早期故障检测纳入同一套可复查流程。

实验结果表明，GRU 序列基线能够在 EarlyFault 任务上取得较稳定表现，并在 RUL 任务上形成可解释的寿命趋势预测。与此同时，预测质量排查也提醒我们：RUL 泛化仍是难点，尤其在跨轴承、跨工况情况下不能夸大精度。本文因此将主线结果、对照模型实验、论文复现实验和演示视频分开表述，保证结论边界清楚。

总体而言，本项目完成了从原始振动信号到特征分析、标签构造、模型训练、结果审计和中文演示材料的完整链路。结合论文复现实验和训练过程视频，当前材料已经具备结题报告、答辩 PPT 和现场演示的基础。

参考文献

- [1] IEEE PHM Society. Ieee phm 2012 data challenge bearing dataset, 2012. Bearing run-to-failure vibration data for prognostics.
- [2] Xianpeng Qiao, Hao Yuan Liow, Veronica Lestari Jauw, and Chin Seong Lim. A comparative study of deep learning model based equipment fault diagnosis and prognosis. *International Journal of Prognostics and Health Management*, 2025.
- [3] Bo Sun, Wenting Hu, Hao Wang, Lei Wang, and Chengyang Deng. Remaining useful life prediction of rolling bearings based on cbam-cnn-lstm. *Sensors*, 25(2):554, 2025.
- [4] USTC/SSE BearingPrediction Project. Bearing feature analysis report. Project archived report, 2026. Feature ranking, feature cards, leakage checks, and feature recommendations.
- [5] USTC/SSE BearingPrediction Project. Final defense asset manifest. Project archived report, 2026. Curated assets and result selection rules for the final defense.
- [6] USTC/SSE BearingPrediction Project. Gru sequence baseline results. Project archived report, 2026. Two datasets, three tasks, 200 epoch GRU sequence baselines.